

Farkas 引理、Fritz John 条件、KKT 条件与 Slater 条件

从 Lax 第 13 章到运筹学约束最优化的一阶条件笔记

整理: ChatGPT
按课堂记号与本地教材路径整理

2026 年 5 月 28 日

摘要

本文把课堂中约束非线性规划的一阶必要条件整理为一条完整链条:

局部最优 $\Rightarrow$ 无可行下降方向 $\Rightarrow$ Fritz John 条件 $\xrightarrow[\text{约束规范条件}]{\lambda_0 > 0}$ KKT 条件.

其中 Farkas-Minkowski 定理是线性代数与凸锥层面的核心工具; Lax 第 13 章给出“非负线性组合”的对偶判据, 运筹学中的 KKT 条件则是将该判据用于目标函数与约束函数在最优点处的一阶线性化。本文同时解释 LICQ、MFCQ、Slater 条件、submersion 类比、KKT 的必要性与充分性, 以及罚函数法和障碍函数法的基本位置。

目录

1 总览: 这几节课到底在讲什么	2
2 基本记号与术语	2
2.1 可行域、局部最优与积极约束	2
2.2 课堂标准形式的符号约定	3
3 Lax 第 13 章: Farkas-Minkowski 是什么	3
3.1 从线性空间的对偶说起	3
3.2 凸锥形式	3
3.3 双锥语言	4
3.4 与凸几何的关系	4
4 Farkas 引理的几种等价形式	4
4.1 一维情形: 为什么老师说显然	4
4.2 Gordan-Farkas 严格形式	4
4.3 锥生成形式	5
4.4 KKT 常用形式	5
5 可行方向、下降方向与一阶线性化	6
5.1 一阶可行方向	6
6 Fritz John 条件: 为什么必须讲它	6
6.1 Fritz John 条件的标准形式	6
6.2 为什么没有正则性时只能保证 FJ	7
6.3 异常情形: 局部最优但没有 KKT	7
7 KKT 条件	8
7.1 标准 KKT 条件	8
7.2 互补松弛的含义	8
7.3 KKT 的几何解释	8

8 约束规范条件：你说的 submersion 类比对不对	9
8.1 一句话结论	9
8.2 等式约束与 submersion	9
8.3 LICQ: 线性无关约束规范	9
8.4 MFCQ: Mangasarian-Fromovitz 条件	10
8.5 Slater 条件: 凸优化中的严格可行性	10
9 局部最优与 KKT: 两个方向分别对不对	10
9.1 局部最优一定满足 KKT 吗	10
9.2 满足 KKT 一定是局部最优吗	11
9.3 什么时候 KKT 充分	11
10 课堂例子：二次函数在三角形上最小化	11
10.1 这个例子中的 Farkas 影子	12
11 障碍函数法与罚函数法：和 KKT/Slater 的位置关系	12
11.1 外点罚函数法	12
11.2 内点障碍函数法	12
12 常见误区与考试记忆	13
12.1 误区一：局部最优一定满足 KKT	13
12.2 误区二：KKT 点一定是局部最优点	13
12.3 误区三：Slater 就是 LICQ	13
12.4 误区四：submersion 可以直接解释所有不等式约束	13
12.5 考试版总结	13
13 Fritz John 条件的证明骨架	13
13.1 只有不等式约束时	14
13.2 加入等式约束时	14
14 法锥、切锥与几何图像	14
14.1 切锥和法锥的最低限度定义	14
14.2 为什么“梯度是外法向”	15
14.3 等值线图像	15
15 约束规范条件的层次与比较	15
15.1 四种常见条件对比	15
15.2 如何理解“信息不足”	15
15.3 你给小鱼的类比如何修正	15
16 更多例子：看清必要性和充分性的边界	16
16.1 KKT 成立但不是最小点	16
16.2 KKT 成立且是全局最优：凸情形	16
16.3 Slater 成立的例子	16
16.4 Slater 失败但问题仍可能有 KKT	16
17 解题模板：如何用 KKT 做题	17
17.1 模板	17
17.2 互补松弛的分情况技巧	17
18 与教材截图的精确对应	17
18.1 Taha 表 20.1 与表 20.2	17
18.2 Hillier-Lieberman 的 regularity conditions	17
18.3 Lax 与运筹学的翻译	17

19 参考路径**18**

1 总览：这几节课到底在讲什么

考虑标准不等式约束极小化问题

$$\min f(x), \quad \text{s.t. } g_i(x) \leq 0, \quad i = 1, \dots, m, \quad (1)$$

其中 $x \in \mathbb{R}^n$ 。课堂中的核心问题是：

如果 x^* 是局部最优点，那么它的一阶微分信息必须满足什么关系？

无约束时，答案是

$$\nabla f(x^*) = 0.$$

有等式约束时，答案是 Lagrange 乘子法：

$$\nabla f(x^*) + \sum_{j=1}^p \nu_j \nabla h_j(x^*) = 0.$$

有不等式约束时，答案需要区分哪些约束真正“顶住”了点 x^* ，于是出现积极约束、可行下降方向、Farkas 引理、Fritz John 条件、KKT 条件。

最小逻辑链。

局部最优 $\Rightarrow$ 不存在可行下降方向 $\Rightarrow$ Farkas/Gordan 替代定理 $\Rightarrow$ FJ 或 KKT 乘子条件。

区别在于：不加正则性通常先得到 Fritz John 条件；加上约束规范条件后，才能把 Fritz John 条件归一化成 KKT 条件。

2 基本记号与术语

2.1 可行域、局部最优与积极约束

定义 2.1 (可行域). 问题 (1) 的可行域为

$$D = \{x \in \mathbb{R}^n : g_i(x) \leq 0, i = 1, \dots, m\}.$$

若还有等式约束 $h_j(x) = 0$ ，则

$$D = \{x \in \mathbb{R}^n : g_i(x) \leq 0, h_j(x) = 0\}.$$

定义 2.2 (局部极小点). 可行点 $x^* \in D$ 称为局部极小点, 如果存在 $\delta > 0$, 使得对所有 $x \in D \cap B_\delta(x^*)$, 都有

$$f(x) \geq f(x^*).$$

若不等号严格成立于所有 $x \neq x^*$ ，则称为严格局部极小点。

定义 2.3 (积极约束/有效约束/紧约束). 对不等式约束 $g_i(x) \leq 0$ ，若

$$g_i(x^*) = 0,$$

则称第 i 个约束在 x^* 处是积极的或有效的。记积极约束指标集为

$$I(x^*) = \{i : g_i(x^*) = 0\}.$$

若 $g_i(x^*) < 0$ ，则称为非积极约束或松弛约束。

备注 2.4 (为什么只关心积极约束). 若 $g_i(x^*) < 0$ ，由连续性可知 x^* 附近足够小的移动仍满足 $g_i(x) < 0$ 。所以它在一阶局部分析中一般不“挡住”方向。真正挡住方向的是 $g_i(x^*) = 0$ 的边界约束。

2.2 课堂标准形式的符号约定

本文主要采用课堂常用形式:

$$\min f(x), \quad g_i(x) \leq 0.$$

在这个约定下, KKT 乘子满足

$$\lambda_i \geq 0,$$

并且 Lagrangian 写作

$$L(x, \lambda) = f(x) + \sum_{i=1}^m \lambda_i g_i(x).$$

如果教材改用 $g_i(x) \geq 0$, 或研究最大化问题, 乘子符号可能反过来。例如 Taha 的表格在最大化/最小化之间采用不同符号约定; 解题时必须先统一成一种标准形式。

3 Lax 第 13 章: Farkas-Minkowski 是什么

3.1 从线性空间的对偶说起

Lax 在 *Linear Algebra and Its Applications* 第 13 章 *The Duality Theorem* 中讨论线性不等式和对偶性。设 X 是 n 维实线性空间, X' 是其对偶空间, 即所有线性函数 $\xi: X \rightarrow \mathbb{R}$ 构成的空间。若把 $x \in X$ 看作列向量, 把 $\xi \in X'$ 看作行向量, 则

$$\xi x = \xi_1 x_1 + \cdots + \xi_n x_n.$$

给定向量 $y_1, \dots, y_m \in X$, 先考虑线性张成

$$Y = \left\{ \sum_{j=1}^m a_j y_j : a_j \in \mathbb{R} \right\}.$$

线性代数里的判据是: $y \in Y$ 当且仅当所有在 y_j 上为零的线性函数 ξ , 也在 y 上为零。也就是

$$\xi y_j = 0 \quad (j = 1, \dots, m) \implies \xi y = 0.$$

Lax 随后把“任意实系数线性组合”换成“非负系数线性组合”。这就从线性子空间进入了凸锥。

3.2 凸锥形式

定义 3.1 (有限生成凸锥). 给定 $y_1, \dots, y_m \in X$, 它们生成的凸锥是

$$K = \text{cone}\{y_1, \dots, y_m\} = \left\{ \sum_{j=1}^m p_j y_j : p_j \geq 0 \right\}.$$

这里没有要求 $\sum_j p_j = 1$, 所以这是锥, 不是凸包。

定理 3.2 (Farkas-Minkowski, Lax Ch.13, Theorem 1). 向量 y 可以写成

$$y = \sum_{j=1}^m p_j y_j, \quad p_j \geq 0,$$

当且仅当: 任意线性函数 $\xi \in X'$ 只要满足

$$\xi y_j \geq 0, \quad j = 1, \dots, m,$$

就必满足

$$\xi y \geq 0.$$

备注 3.3 (一句话翻译). 若所有在锥 K 上非负的线性函数都在 y 上非负, 则 y 必在这个锥中。若 y 不在锥中, 就存在一个线性函数把 y 与锥分开。

3.3 双锥语言

定义对偶锥

$$K^* = \{\xi \in X' : \xi z \geq 0, \forall z \in K\}.$$

由于 K 由 y_j 生成, $\xi \in K^*$ 等价于

$$\xi y_j \geq 0, \quad j = 1, \dots, m.$$

于是 Lax 的定理可写成

$$y \in K \iff \xi y \geq 0, \quad \forall \xi \in K^*.$$

即

$$K = (K^*)^*.$$

这就是有限生成闭凸锥的双对偶性质。

3.4 与凸几何的关系

Lax 第 12 章 *Convexity* 先讲 convex sets, gauge function, Hahn-Banach theorem, support function, Carathéodory theorem, Helly theorem 等内容; 第 13 章把这些思想用于线性不等式。几何本质是:

若一个点不在闭凸集或闭凸锥中, 则可以用一个超平面把它分离出去。

所以 Farkas 引理不是孤立技巧, 而是“分离超平面定理”在有限维线性不等式系统中的代数化。

4 Farkas 引理的几种等价形式

4.1 一维情形: 为什么老师说显然

先看 $a, c \in \mathbb{R}$ 。问是否存在 $d \in \mathbb{R}$, 使

$$ad < 0, \quad cd < 0.$$

若 a, c 同号, 则取相反符号的 d 即可。若 a, c 异号, 则一个条件要求 $d > 0$, 另一个要求 $d < 0$, 矛盾。若某个系数为 0, 如 $a = 0$, 则 $ad = 0$ 永远不可能 < 0 。

无解时, 存在非负数 $\alpha, \beta \geq 0$, 不全为零, 使

$$\alpha a + \beta c = 0.$$

例如 $a > 0, c < 0$ 时可取 $\alpha = -c, \beta = a$ 。

一维本质:

$$\nexists d : ad < 0, cd < 0 \iff \exists \alpha, \beta \geq 0 \text{ not all zero} : \alpha a + \beta c = 0.$$

高维版本就是: 若找不到一个方向同时使若干内积都为负, 则这些向量之间存在非负线性组合为零。

4.2 Gordan-Farkas 严格形式

定理 4.1 (Gordan-Farkas 替代定理). 给定 $v_0, v_1, \dots, v_r \in \mathbb{R}^n$ 。下列二者恰有一个成立:

1. 存在 $d \in \mathbb{R}^n$, 使

$$v_i^T d < 0, \quad i = 0, 1, \dots, r.$$

2. 存在 $\alpha_i \geq 0$, 不全为零, 使

$$\sum_{i=0}^r \alpha_i v_i = 0.$$

证明思路：凸包版本. 令

$$C = \text{conv}\{v_0, \dots, v_r\} = \left\{ \sum_i \alpha_i v_i : \alpha_i \geq 0, \sum_i \alpha_i = 1 \right\}.$$

若 $0 \in C$, 则存在 $\alpha_i \geq 0, \sum_i \alpha_i = 1$ 使 $\sum_i \alpha_i v_i = 0$. 若又存在 d 使所有 $v_i^T d < 0$, 则

$$0 = \left(\sum_i \alpha_i v_i \right)^T d = \sum_i \alpha_i v_i^T d < 0,$$

矛盾。

反过来, 若 $0 \notin C$, 因 C 是紧凸集, 取 $p \in C$ 使 $\|p\| = \min_{y \in C} \|y\|$. 则 $p \neq 0$. 对任意 $y \in C$, 函数

$$\phi(t) = \|p + t(y - p)\|^2, \quad 0 \leq t \leq 1,$$

在 $t = 0$ 的右导数非负, 故

$$p^T(y - p) \geq 0, \quad p^T y \geq \|p\|^2 > 0.$$

特别对 $y = v_i$, 有 $p^T v_i > 0$. 取 $d = -p$, 则

$$v_i^T d = -p^T v_i < 0.$$

故存在共同严格下降方向。 □

4.3 锥生成形式

定理 4.2 (Farkas, 锥形式). 给定 $a_1, \dots, a_m, b \in \mathbb{R}^n$. 以下二者等价:

1. $b \in \text{cone}\{a_1, \dots, a_m\}$, 即存在 $\lambda_i \geq 0$, 使

$$b = \sum_{i=1}^m \lambda_i a_i.$$

2. 对任意 $d \in \mathbb{R}^n$, 若

$$a_i^T d \geq 0, \quad i = 1, \dots, m,$$

则

$$b^T d \geq 0.$$

这个形式与 Lax 的 Theorem 1 完全同型。把 a_i 看成 Lax 的 y_i , 把 b 看成 Lax 的 y 即可。

4.4 KKT 常用形式

在 KKT 推导中, 常用下面的版本:

定理 4.3 (KKT 常用的替代形式). 给定 $a_1, \dots, a_m, c \in \mathbb{R}^n$. 下列二者恰有一个成立:

1. 存在 d , 使

$$a_i^T d \leq 0, \quad i = 1, \dots, m, \quad c^T d < 0.$$

2. 存在 $\lambda_i \geq 0$, 使

$$c + \sum_{i=1}^m \lambda_i a_i = 0.$$

几何上, $a_i^T d \leq 0$ 描述一阶可行方向, $c^T d < 0$ 描述目标下降。若不存在这样的 d , 则 $-c$ 落在由 a_i 生成的非负锥中。

5 可行方向、下降方向与一阶线性化

5.1 一阶可行方向

设 x^* 可行, 且 g_i 在 x^* 可微. 对积极约束 $i \in I(x^*)$, Taylor 展开给出

$$g_i(x^* + td) = g_i(x^*) + t\nabla g_i(x^*)^T d + o(t) = t\nabla g_i(x^*)^T d + o(t).$$

因此如果

$$\nabla g_i(x^*)^T d < 0,$$

则沿 d 小步前进会进入约束内部. 若采用闭的线性化可行条件, 则写成

$$\nabla g_i(x^*)^T d \leq 0.$$

定义 5.1 (线性化可行锥). 只有不等式约束时, 在 x^* 处的线性化可行锥定义为

$$L_D(x^*) = \{d \in \mathbb{R}^n : \nabla g_i(x^*)^T d \leq 0, i \in I(x^*)\}.$$

若还有等式约束 $h_j(x) = 0$, 则加入

$$\nabla h_j(x^*)^T d = 0, \quad j = 1, \dots, p.$$

定义 5.2 (可行下降方向). 方向 d 称为可行下降方向, 粗略地说是: 沿它走一小步仍可行, 且目标函数下降. 一阶充分判据为

$$\nabla g_i(x^*)^T d < 0 \quad (i \in I(x^*)), \quad \nabla f(x^*)^T d < 0.$$

若只用闭锥语言, 则常写成

$$d \in L_D(x^*), \quad \nabla f(x^*)^T d < 0.$$

命题 5.3 (局部最优点处无可行下降方向). 若 x^* 是局部极小点, 则不存在方向 d 和充分小 $t > 0$ 使 $x^* + td \in D$ 且 $f(x^* + td) < f(x^*)$. 特别地, 在正则情形下, 不存在 $d \in L_D(x^*)$ 使

$$\nabla f(x^*)^T d < 0.$$

Proof. 若存在这样的 d , 则 $x^* + td$ 是任意靠近 x^* 的可行点, 却有更小函数值, 直接与局部极小定义矛盾. $\square$

6 Fritz John 条件: 为什么必须讲它

6.1 Fritz John 条件的标准形式

考虑含等式和不等式约束的问题

$$\begin{aligned} \min \quad & f(x) \\ \text{s.t.} \quad & g_i(x) \leq 0, \quad i = 1, \dots, m, \\ & h_j(x) = 0, \quad j = 1, \dots, p. \end{aligned} \tag{2}$$

定理 6.1 (Fritz John 必要条件). 设 x^* 是 (2) 的局部极小点, 并假设相关函数在 x^* 附近具有相应可微性. 则存在乘子

$$\lambda_0 \geq 0, \quad \lambda_i \geq 0 \quad (i = 1, \dots, m), \quad \nu_j \in \mathbb{R} \quad (j = 1, \dots, p),$$

不全为零, 使得

$$\lambda_0 \nabla f(x^*) + \sum_{i=1}^m \lambda_i \nabla g_i(x^*) + \sum_{j=1}^p \nu_j \nabla h_j(x^*) = 0, \tag{3}$$

$$\lambda_i g_i(x^*) = 0, \quad i = 1, \dots, m, \tag{4}$$

$$\lambda_i \geq 0, \quad i = 1, \dots, m. \tag{5}$$

备注 6.2 (FJ 比 KKT 多了什么). Fritz John 条件比 KKT 多了一个目标函数前面的乘子 λ_0 。如果 $\lambda_0 > 0$, 可以两边除以 λ_0 , 令

$$\tilde{\lambda}_i = \lambda_i / \lambda_0, \quad \tilde{\nu}_j = \nu_j / \lambda_0,$$

就得到 KKT 条件。若 $\lambda_0 = 0$, 则目标函数梯度从驻点方程中消失, 这称为异常情形或退化情形。

Fritz John 的角色。

局部最优 $\Rightarrow$ Fritz John 条件

通常不需要像 LICQ/MFCQ 那样强的约束规范条件; 而

Fritz John + $\lambda_0 > 0 \Rightarrow$ KKT.

约束规范条件的主要作用就是排除 $\lambda_0 = 0$ 的异常情况。

6.2 为什么没有正则性时只能保证 FJ

局部最优点处没有可行下降方向。把这个“无解”系统丢给 Gordan-Farkas 替代定理, 通常得到的是

$$\lambda_0 \nabla f(x^*) + \sum_{i \in I(x^*)} \lambda_i \nabla g_i(x^*) + \sum_{j=1}^p \nu_j \nabla h_j(x^*) = 0,$$

其中 $\lambda_0, \lambda_i \geq 0$, 且不全为零。由于替代定理只保证“不全为零”, 它没有自动保证 $\lambda_0 > 0$ 。所以最原始的结论就是 FJ, 而不是 KKT。

6.3 异常情形: 局部最优但没有 KKT

例 6.3 (局部最优但 KKT 失败). 考虑

$$\min f(x) = x, \quad \text{s.t. } g(x) = x^2 \leq 0.$$

可行域为

$$D = \{0\}.$$

所以 $x^* = 0$ 是全局最优点。

KKT 要求存在 $\lambda \geq 0$, 使

$$f'(0) + \lambda g'(0) = 0.$$

但

$$f'(0) = 1, \quad g'(0) = 0,$$

于是

$$1 + \lambda \cdot 0 = 0$$

不可能。因此 0 是最优点但不满足 KKT。

Fritz John 条件却成立: 取

$$\lambda_0 = 0, \quad \lambda = 1,$$

则

$$\lambda_0 f'(0) + \lambda g'(0) = 0 \cdot 1 + 1 \cdot 0 = 0.$$

这是典型异常情形。

备注 6.4 (这个反例说明什么). 约束 $x^2 \leq 0$ 把可行域压成一个点, 但一阶梯度 $g'(0) = 0$ 完全看不出约束的边界信息。这就是你说的“信息不足”的精确含义: 约束的一阶线性化失真, 无法反映真实可行域结构。

7 KKT 条件

7.1 标准 KKT 条件

对问题 (2), KKT 条件为: 存在乘子

$$\lambda_i \geq 0, \quad i = 1, \dots, m, \quad \nu_j \in \mathbb{R}, \quad j = 1, \dots, p,$$

使得

$$\nabla f(x^*) + \sum_{i=1}^m \lambda_i \nabla g_i(x^*) + \sum_{j=1}^p \nu_j \nabla h_j(x^*) = 0, \quad (6)$$

$$g_i(x^*) \leq 0, \quad h_j(x^*) = 0, \quad (7)$$

$$\lambda_i \geq 0, \quad (8)$$

$$\lambda_i g_i(x^*) = 0. \quad (9)$$

四类条件分别叫:

- **stationarity** / 驻点条件: 拉格朗日函数对 x 的梯度为零;
- **primal feasibility** / 原可行性: x^* 满足原约束;
- **dual feasibility** / 对偶可行性: 不等式乘子非负;
- **complementary slackness** / 互补松弛: 只有积极约束可能有非零乘子。

7.2 互补松弛的含义

因为

$$\lambda_i \geq 0, \quad g_i(x^*) \leq 0, \quad \lambda_i g_i(x^*) = 0,$$

所以

$$\begin{aligned} g_i(x^*) < 0 &\implies \lambda_i = 0, \\ \lambda_i > 0 &\implies g_i(x^*) = 0. \end{aligned}$$

非积极约束没有“顶住”点, 因此乘子为零; 积极约束才可能有非零“反作用力”。

7.3 KKT 的几何解释

只有不等式约束时, 驻点条件可写成

$$-\nabla f(x^*) = \sum_{i \in I(x^*)} \lambda_i \nabla g_i(x^*), \quad \lambda_i \geq 0.$$

右边是积极约束外法向量生成的锥:

$$\text{cone}\{\nabla g_i(x^*) : i \in I(x^*)\}.$$

因此 KKT 表示

$$-\nabla f(x^*) \in \text{cone}\{\nabla g_i(x^*) : i \in I(x^*)\}.$$

也就是说, 目标函数最想下降的方向被约束边界的法向锥挡住了。

8 约束规范条件：你说的 **submersion** 类比对不对

8.1 一句话结论

你的直觉“约束规范条件是在排除信息不足，类似 Jacobi 矩阵满秩/submersion”是很接近的，但要稍微修正：

- 对等式约束 $h(x) = 0$ ， $Dh(x^*)$ 满秩确实就是 **submersion** 条件；这保证 $h^{-1}(0)$ 局部是光滑子流形。
- 对不等式约束，应只看积极约束 $g_i(x^*) = 0$ 。它们的梯度要以某种方式独立/非退化，使线性化可行锥正确反映真实可行方向。
- LICQ 是“活动约束梯度线性无关”；MFCQ 是“存在一个方向严格进入所有活动不等式内部，同时保持等式切向”；Slater 是凸优化中的“严格可行点存在”。

所以，**submersion** 是等式约束正则性的微分几何版本；不等式约束的正则性更像“活动边界的法向锥不是病态的”。

8.2 等式约束与 **submersion**

考虑

$$h : \mathbb{R}^n \rightarrow \mathbb{R}^p, \quad h(x) = 0.$$

若

$$\text{rank } Dh(x^*) = p,$$

即 Jacobi 矩阵满行秩，则 h 在 x^* 处是 **submersion**。由正则水平集定理，

$$M = h^{-1}(0)$$

在 x^* 附近是一个 $n - p$ 维光滑子流形，并且切空间为

$$T_{x^*}M = \ker Dh(x^*) = \{d : \nabla h_j(x^*)^T d = 0, j = 1, \dots, p\}.$$

此时一阶线性化准确描述约束集的切空间。

备注 8.1. 这就是你提到“切映射满射”的精确版本： $Dh(x^*) : \mathbb{R}^n \rightarrow \mathbb{R}^p$ 满射，所以约束方程 $h = 0$ 局部确实切出一个正则子流形。

8.3 LICQ：线性无关约束规范

定义 8.2 (LICQ). 在 x^* 处，若向量组

$$\{\nabla g_i(x^*) : i \in I(x^*)\} \cup \{\nabla h_j(x^*) : j = 1, \dots, p\}$$

线性无关，则称 x^* 满足 LICQ (linear independence constraint qualification)。

LICQ 的作用是排除 FJ 中 $\lambda_0 = 0$ 。若 FJ 异常，即 $\lambda_0 = 0$ ，则

$$\sum_{i \in I(x^*)} \lambda_i \nabla g_i(x^*) + \sum_{j=1}^p \nu_j \nabla h_j(x^*) = 0,$$

且乘子不全为零。这正是活动约束梯度的非平凡线性关系，与 LICQ 矛盾。因此 $\lambda_0 > 0$ ，可以归一化为 KKT。

8.4 MFCQ: Mangasarian-Fromovitz 条件

LICQ 比较强。更常见的充分正则条件是 MFCQ。

定义 8.3 (MFCQ). 设 x^* 可行。若

1. 等式约束梯度 $\nabla h_1(x^*), \dots, \nabla h_p(x^*)$ 线性无关;
2. 存在方向 d , 使

$$\nabla h_j(x^*)^T d = 0, \quad j = 1, \dots, p,$$

且

$$\nabla g_i(x^*)^T d < 0, \quad i \in I(x^*),$$

则称 x^* 满足 MFCQ。

直观上, MFCQ 要求存在一个方向沿等式约束的切空间移动, 同时严格进入所有活动不等式的内部。它说明活动不等式没有把点用一阶信息“夹死”到无法辨认。

备注 8.4 (LICQ 与 MFCQ 的关系). 在一般情形下, LICQ 推出 MFCQ; MFCQ 通常弱于 LICQ。课程中若只讲线性无关条件, 多半是在用 LICQ 作为简单版本。

8.5 Slater 条件: 凸优化中的严格可行性

考虑凸优化问题

$$\begin{aligned} \min \quad & f_0(x) \\ \text{s.t.} \quad & f_i(x) \leq 0, \quad i = 1, \dots, m, \\ & Ax = b, \end{aligned} \tag{10}$$

其中 f_0, f_i 为凸函数, 等式约束是仿射的。

定义 8.5 (Slater 条件). 若存在一点 $\bar{x} \in \text{ri}(\text{dom } f_0 \cap \dots \cap \text{dom } f_m)$, 使

$$f_i(\bar{x}) < 0, \quad i = 1, \dots, m, \quad A\bar{x} = b,$$

则称问题满足 Slater 条件。

若某些不等式约束本身是仿射的, Boyd 中还给出 **refined Slater condition**: 仿射不等式可不要求严格小于零, 只需满足非严格可行; 非仿射凸不等式仍要求严格可行。

Slater 的作用。 在凸优化中, Slater 条件保证强对偶, 并保证 KKT 条件在适当可达情形下成为最优性的必要条件; 而对凸问题, KKT 本身又是充分条件。因此常概括为:

$$\text{凸问题} + \text{Slater} \implies \text{KKT 是最优性的必要且充分条件。}$$

更精确地说: 凸性给 KKT 的充分性; Slater 主要给强对偶与乘子存在, 从而给必要性。

9 局部最优与 KKT: 两个方向分别对不对

9.1 局部最优一定满足 KKT 吗

一般不一定。正确说法是:

$$\boxed{\text{局部最优} + \text{约束规范条件} \implies \text{KKT}.}$$

若不加约束规范条件, 只能一般得到 Fritz John 条件; KKT 可能失败。前面的例子

$$\min x, \quad x^2 \leq 0$$

就是局部最优但 KKT 失败。

9.2 满足 KKT 一定是局部最优吗

一般也不一定。最简单反例是无约束问题

$$\min f(x) = -x^2.$$

无约束 KKT 就是 $f'(x^*) = 0$ 。在 $x^* = 0$ 处满足

$$f'(0) = 0,$$

但 0 是局部极大点，不是局部极小点。

所以在非凸问题中，KKT 只是候选点条件，不是充分条件。

9.3 什么时候 KKT 充分

若问题是凸规划：

- 目标函数 f_0 凸；
- 不等式约束函数 f_i 凸；
- 等式约束仿射；

那么任何满足 KKT 的可行点都是全局最优点。

证明很短。若

$$L(x, \lambda, \nu) = f_0(x) + \sum_i \lambda_i f_i(x) + \nu^T (Ax - b),$$

且 $\lambda_i \geq 0$ ，则 $L(\cdot, \lambda, \nu)$ 是凸函数。若 KKT 驻点成立，则 x^* 是 L 的全局极小点。因此对任意可行 x ，

$$f_0(x) \geq L(x, \lambda, \nu) \geq L(x^*, \lambda, \nu) = f_0(x^*),$$

其中最后一步用互补松弛与可行性。

10 课堂例子：二次函数在三角形上最小化

考虑

$$\min f(x) = x_1^2 + x_2^2 - 6x_1 - 6x_2 + 8$$

约束为

$$x_1 + x_2 \leq 4, \quad x_1 \geq 0, \quad x_2 \geq 0.$$

统一写成 $g_i \leq 0$ ：

$$g_1 = x_1 + x_2 - 4, \quad g_2 = -x_1, \quad g_3 = -x_2.$$

目标函数配方为

$$f(x) = (x_1 - 3)^2 + (x_2 - 3)^2 - 10.$$

无约束极小点为 $(3, 3)$ ，但不可行，因为 $3 + 3 > 4$ 。可行域是第一象限中 $x_1 + x_2 \leq 4$ 的三角形，直观上最优点是 $(2, 2)$ 。

计算梯度：

$$\nabla f = (2x_1 - 6, 2x_2 - 6)^T,$$

$$\nabla g_1 = (1, 1)^T, \quad \nabla g_2 = (-1, 0)^T, \quad \nabla g_3 = (0, -1)^T.$$

KKT 条件为

$$\nabla f(x^*) + \lambda_1 \nabla g_1(x^*) + \lambda_2 \nabla g_2(x^*) + \lambda_3 \nabla g_3(x^*) = 0,$$

$$\lambda_i \geq 0, \quad g_i(x^*) \leq 0, \quad \lambda_i g_i(x^*) = 0.$$

猜 $x^* = (2, 2)$ 。此时

$$g_1(2, 2) = 0, \quad g_2(2, 2) = -2 < 0, \quad g_3(2, 2) = -2 < 0.$$

故由互补松弛

$$\lambda_2 = \lambda_3 = 0.$$

驻点条件化为

$$(-2, -2)^T + \lambda_1(1, 1)^T = 0,$$

所以

$$\lambda_1 = 2.$$

于是

$$x^* = (2, 2), \quad \lambda = (2, 0, 0)$$

满足 KKT。

因为 f 严格凸, 约束线性, 可行域凸, 所以 KKT 充分, x^* 是唯一全局最优解。最优值

$$f(2, 2) = -8.$$

10.1 这个例子中的 Farkas 影子

在 $(2, 2)$ 处, 唯一积极约束是 g_1 。若存在可行下降方向 $d = (d_1, d_2)^T$, 则要满足

$$\nabla g_1(2, 2)^T d = d_1 + d_2 < 0,$$

同时目标下降要求

$$\nabla f(2, 2)^T d = (-2, -2)d = -2(d_1 + d_2) < 0,$$

即

$$d_1 + d_2 > 0.$$

矛盾。Farkas 给出的代数证书正是

$$\nabla f(2, 2) + 2\nabla g_1(2, 2) = 0.$$

11 障碍函数法与罚函数法: 和 KKT/Slater 的位置关系

课堂后续进入惩罚函数法与障碍函数法。它们不是 KKT 条件本身, 而是把约束问题转化为无约束问题的数值方法。

11.1 外点罚函数法

对约束问题

$$\min f(x), \quad g_i(x) \leq 0,$$

可构造罚函数

$$P_r(x) = f(x) + r \sum_{i=1}^m \max\{0, g_i(x)\}^2, \quad r \rightarrow +\infty.$$

不可行点如果违反约束, 则 $\max\{0, g_i(x)\}^2$ 产生惩罚。随着 r 变大, 无约束极小点被迫靠近可行域。

11.2 内点障碍函数法

若可行域有内部

$$D^\circ = \{x : g_i(x) < 0, \quad i = 1, \dots, m\},$$

可构造障碍函数

$$B(x) = - \sum_{i=1}^m \log(-g_i(x))$$

或

$$B(x) = - \sum_{i=1}^m \frac{1}{g_i(x)}$$

在 D° 内优化

$$f(x) + \mu B(x), \quad \mu \downarrow 0.$$

当 x 逼近边界 $g_i(x) = 0$ 时, $B(x) \rightarrow +\infty$, 所以迭代点被留在内部。

备注 11.1 (与 Slater 的关系). 障碍函数法需要可行域有严格内部点; 这与 Slater 条件的“严格可行点存在”在直观上非常接近。Slater 是理论上的正则条件; 障碍函数法则把“从内部逼近边界最优点”变成算法思想。

12 常见误区与考试记忆

12.1 误区一：局部最优一定满足 KKT

错误。应改为：

$$\text{局部最优} + \text{约束规范条件} \Rightarrow \text{KKT}.$$

无正则性时，一般先得 Fritz John。

12.2 误区二：KKT 点一定是局部最优点

错误。非凸问题中 KKT 只是候选条件。凸规划中 KKT 才是充分条件。

12.3 误区三：Slater 就是 LICQ

错误。LICQ 是点态微分条件，看活动约束梯度是否线性无关；Slater 是凸优化中的全局严格可行性条件。两者都属于 constraint qualification，但形式和适用场景不同。

12.4 误区四：submersion 可以直接解释所有不等式约束

不完全对。对等式约束 $h = 0$ ，满秩 Dh 正是 submersion。对不等式约束，只有活动边界 $g_i = 0$ 起作用，需要看活动约束梯度及法向锥结构。若活动约束梯度为零或线性相关过强，一阶信息可能失效。

12.5 考试版总结

1. 写标准形式：统一成 $\min f(x), g_i(x) \leq 0, h_j(x) = 0$ 。
2. 找积极约束： $I(x^*) = \{i : g_i(x^*) = 0\}$ 。
3. 写 KKT：驻点、原可行、对偶可行、互补松弛。
4. 判断必要性：局部最优加约束规范条件推出 KKT；无正则性只保证 FJ。
5. 判断充分性：凸目标 + 凸不等式 + 仿射等式时，KKT 推出全局最优。
6. Slater：凸优化中存在严格可行点，保证强对偶和乘子存在，使 KKT 成为必要且充分的标准工具。

13 Fritz John 条件的证明骨架

本节把“为什么先得到 FJ，而不是直接得到 KKT”写得更清楚一些。为避免技术细节淹没主线，先只处理不等式约束，再说明等式约束如何加入。

13.1 只有不等式约束时

问题为

$$\min f(x), \quad g_i(x) \leq 0, \quad i = 1, \dots, m.$$

设 x^* 是局部极小点, $I = I(x^*)$ 。若存在方向 d 使

$$\nabla f(x^*)^T d < 0, \quad \nabla g_i(x^*)^T d < 0, \quad i \in I,$$

则 d 是可行下降方向, 矛盾。因此严格线性不等式系统无解:

$$v_0^T d < 0, \quad v_i^T d < 0 \quad (i \in I),$$

其中

$$v_0 = \nabla f(x^*), \quad v_i = \nabla g_i(x^*).$$

由 Gordan-Farkas, 存在

$$\lambda_0 \geq 0, \quad \lambda_i \geq 0 \quad (i \in I),$$

不全为零, 使

$$\lambda_0 \nabla f(x^*) + \sum_{i \in I} \lambda_i \nabla g_i(x^*) = 0.$$

对 $i \notin I$ 令 $\lambda_i = 0$, 则有

$$\lambda_i g_i(x^*) = 0, \quad i = 1, \dots, m.$$

这就是 Fritz John 条件。

13.2 加入等式约束时

若还有等式约束 $h_j(x) = 0$, 沿可行曲线的一阶方向必须满足

$$\nabla h_j(x^*)^T d = 0, \quad j = 1, \dots, p.$$

等式条件可拆成两个不等式方向, 或者更自然地在 Farkas 替代定理中允许等式乘子 $\nu_j \in \mathbb{R}$ 。最终得到

$$\lambda_0 \nabla f(x^*) + \sum_{i=1}^m \lambda_i \nabla g_i(x^*) + \sum_{j=1}^p \nu_j \nabla h_j(x^*) = 0,$$

其中不等式乘子非负, 等式乘子符号自由。

备注 13.1 (为什么等式乘子符号自由). 等式 $h_j(x) = 0$ 没有“内侧/外侧”的方向区别。把 $h_j = 0$ 写成 $h_j \leq 0$ 和 $-h_j \leq 0$, 两个非负乘子相减后自然得到一个任意实数乘子。

14 法锥、切锥与几何图像

14.1 切锥和法锥的最低限度定义

在凸分析中, 若 $D \subset \mathbb{R}^n$ 是凸集, $x^* \in D$, 常定义法锥

$$N_D(x^*) = \{v \in \mathbb{R}^n : v^T(x - x^*) \leq 0, \forall x \in D\}.$$

它收集所有在 x^* 处支撑可行域的外法向量。

局部最优的凸几何表述是

$$-\nabla f(x^*) \in N_D(x^*).$$

若 $D = \{x : g_i(x) \leq 0, h_j(x) = 0\}$ 且正则条件成立, 则

$$N_D(x^*) = \text{cone}\{\nabla g_i(x^*) : i \in I(x^*)\} + \text{span}\{\nabla h_j(x^*) : j = 1, \dots, p\}.$$

这里第一部分来自不等式法向锥, 第二部分来自等式约束的法空间。于是

$$-\nabla f(x^*) \in \text{cone}\{\nabla g_i(x^*) : i \in I(x^*)\} + \text{span}\{\nabla h_j(x^*)\},$$

这正是 KKT 驻点条件。

备注 14.1 (正则性的重要性). 上面关于法锥的表示一般需要约束规范条件; 没有正则性时, 真实法锥可能比活动梯度生成的锥更大, KKT 乘子条件就可能漏掉局部最优点。

14.2 为什么“梯度是外法向”

对约束 $g(x) \leq 0$ ，在边界点 $g(x^*) = 0$ 附近，梯度 $\nabla g(x^*)$ 指向 g 增大的方向。因为

$$g(x^* + td) = g(x^*) + t\nabla g(x^*)^T d + o(t).$$

若 $\nabla g(x^*)^T d > 0$ ，则小 $t > 0$ 时 g 变正，走到不可行侧。因此 $\nabla g(x^*)$ 是约束边界的外法向量。

14.3 等值线图像

二维中，目标函数等值线 $f(x) = c$ 与可行域边界相切时，通常出现 KKT 关系。若一个活动边界 $g_1(x) = 0$ 起作用，则

$$\nabla f(x^*) = -\lambda_1 \nabla g_1(x^*), \quad \lambda_1 \geq 0.$$

若两个边界同时起作用，则

$$-\nabla f(x^*) \in \text{cone}\{\nabla g_1(x^*), \nabla g_2(x^*)\}.$$

所以“相切”在多个不等式约束下不再是简单平行，而是落在一个法向锥内。

15 约束规范条件的层次与比较

15.1 四种常见条件对比

名称	数学表述	作用与直观
LICQ	活动不等式梯度与等式梯度线性无关	最强且最容易检查；保证 FJ 中 $\lambda_0 > 0$ ，乘子通常局部唯一。
MFCQ	等式梯度线性无关，且存在方向 d 保持等式切向并严格进入所有活动不等式内部	比 LICQ 弱；排除活动约束一阶信息把点异常夹死。
Slater	凸问题存在严格可行点 $\bar{x}$ ，使非仿射凸不等式严格满足	凸优化专用；保证强对偶和 KKT 乘子存在。
等式 submersion	$Dh(x^*)$ 满行秩	由正则水平集定理， $h^{-1}(0)$ 是光滑子流形，切空间由 $Dh(x^*)d = 0$ 给出。

15.2 如何理解“信息不足”

约束规范条件不是为了让最优点存在，而是为了让“约束的一阶线性化”足够忠实。失败方式通常有三类：

1. **零梯度退化**：如 $x^2 \leq 0$ 在 0 处梯度为 0，但真实可行域只有一个点。
2. **活动约束线性相关过强**：多个边界的法向量给出重复或矛盾的一阶信息，乘子可能不唯一或异常。
3. **没有内点**：凸问题中若没有严格可行点，分离超平面可能退化为“竖直支撑”，导致强对偶或乘子存在性失败。

15.3 你给小鱼的类比如何修正

可以对小鱼这样说：

约束规范条件大致是在说：约束的一阶信息没有退化，线性化出来的切空间/可行方向能真实反映可行集附近的几何。等式约束时，这正是 Jacobi 矩阵满秩，也就是微分几何里的 **submersion**；不等式约束时，要只看活动约束，并要求它们的梯度生成的法向锥不是病态的，例如 LICQ 或 MFCQ。凸优化里的 Slater 条件则是另一种正则性：要求存在严格可行点，从全局凸几何上排除对偶分离的退化。

16 更多例子：看清必要性和充分性的边界

16.1 KKT 成立但不是最小点

考虑无约束问题

$$\min f(x) = x^3.$$

在 $x^* = 0$ 处,

$$f'(0) = 0,$$

满足无约束 KKT。但 x^3 在 0 附近既取正也取负, 0 不是局部极小点。这个例子说明: 一阶条件甚至无法区分鞍点、极大点和极小点。

16.2 KKT 成立且是全局最优: 凸情形

考虑

$$\min (x - 2)^2, \quad x \leq 1.$$

写作 $g(x) = x - 1 \leq 0$ 。显然最优点是 $x^* = 1$ 。KKT:

$$f'(x) = 2(x - 2), \quad g'(x) = 1.$$

驻点条件

$$2(1 - 2) + \lambda = 0$$

给出

$$\lambda = 2 \geq 0.$$

互补松弛成立, 因为 $g(1) = 0$ 。由于目标凸、约束仿射, 所以 KKT 充分。

16.3 Slater 成立的例子

问题

$$\min x^2, \quad x - 1 \leq 0$$

满足 Slater, 因为取 $\bar{x} = 0$ 有

$$\bar{x} - 1 = -1 < 0.$$

这是严格可行点。

16.4 Slater 失败但问题仍可能有 KKT

Slater 是充分正则条件, 不是必要条件。比如

$$\min x^2, \quad x \leq 0, \quad -x \leq 0.$$

可行域只有 $x = 0$, 没有严格满足两个不等式的点, 因此 Slater 失败。但 $x^* = 0$ 仍可满足 KKT:

$$0 + \lambda_1 - \lambda_2 = 0, \quad \lambda_1, \lambda_2 \geq 0.$$

取 $\lambda_1 = \lambda_2 = 0$ 即可。这里说明: Slater 失败不代表 KKT 一定失败; 它只是不能作为通用保证。

17 解题模板：如何用 KKT 做题

17.1 模板

给定题目后，按以下步骤：

1. **统一标准形式**：写成 $\min f(x)$, $g_i(x) \leq 0$, $h_j(x) = 0$ 。

2. 写 **Lagrangian**：

$$L = f + \sum_i \lambda_i g_i + \sum_j \nu_j h_j.$$

3. 列 **KKT**：

$$\nabla_x L = 0, \quad g_i \leq 0, \quad h_j = 0, \quad \lambda_i \geq 0, \quad \lambda_i g_i = 0.$$

4. **分活动集讨论**：根据 $g_i = 0$ 或 $g_i < 0$ ，用互补松弛决定 λ_i 是否为零。

5. **解方程组并检查符号**：特别检查 $\lambda_i \geq 0$ 和可行性。

6. **判断是否全局最优**：若是凸规划，则 KKT 解即全局最优；否则只是候选点，还需二阶条件或直接比较。

17.2 互补松弛的分情况技巧

对每个不等式约束，只有两种情况：

$$\begin{cases} g_i(x^*) = 0, & \lambda_i \geq 0 \text{ 可非零}, \\ g_i(x^*) < 0, & \lambda_i = 0. \end{cases}$$

考试中通常先根据几何判断活动集，再代入 KKT。若几何不明显，则枚举活动集。

18 与教材截图的精确对应

18.1 Taha 表 20.1 与表 20.2

Taha 在 Chapter 20 的 KKT 章节中区分了必要条件与充分条件。表 20.1 的核心意思是：

- 最大化问题：目标函数凹、解空间凸时，KKT 必要条件也是充分条件；
- 最小化问题：目标函数凸、解空间凸时，KKT 必要条件也是充分条件。

表 20.2 进一步给出一组更便于实践检查的充分条件：目标函数和约束函数的凸/凹/线性组合能保证对应的 Lagrangian 具有合适凸性或凹性。

需要注意的是，Taha 的符号约定与课堂可能不同。例如在截图里最小化问题下写出 $\lambda \leq 0$ ，这是因为他采用的 Lagrangian 或约束方向和我们这里不同。统一成本文的约定 $g_i \leq 0$ 、 $L = f + \sum \lambda_i g_i$ 后，最小化问题应写 $\lambda_i \geq 0$ 。

18.2 Hillier-Lieberman 的 regularity conditions

Hillier-Lieberman 在 KKT 定理前说假设 f, g_i 可微并满足 certain regularity conditions。这里的 regularity conditions 就是本文说的 constraint qualifications。教材为了运筹学应用通常不展开证明细节；数学上它们负责把 Fritz John 条件中的 λ_0 排除为零，从而推出标准 KKT。

18.3 Lax 与运筹学的翻译

Lax 讲的是：

$$y \in \text{cone}\{y_j\} \iff \text{所有在 } y_j \text{ 上非负的线性函数也在 } y \text{ 上非负.}$$

KKT 用的是：

$$-\nabla f(x^*) \in \text{cone}\{\nabla g_i(x^*) : i \in I(x^*)\} + \text{span}\{\nabla h_j(x^*)\}.$$

所以 Lax 的 Farkas-Minkowski 是 KKT 乘子存在性的线性代数核心。

19 参考路径

1. Peter D. Lax, *Linear Algebra and Its Applications*, 2nd ed. Chapter 12 *Convexity*, pp.187–199: convex sets, gauge function, Hahn–Banach theorem, support function, Carathéodory theorem, Helly theorem. Chapter 13 *The Duality Theorem*, pp.202–210: Farkas–Minkowski Theorem, Duality Theorem, economics interpretation, minmax theorem. 重点: Theorem 1 (Farkas–Minkowski), p.203.
2. Stephen Boyd and Lieven Vandenberghe, *Convex Optimization*. Chapter 2.5–2.6: separating/supporting hyperplanes, dual cones. Chapter 5.2.3: Strong duality and Slater’s constraint qualification. Chapter 5.5.3: KKT conditions for convex problems. Chapter 5.8: Theorems of alternatives.
3. Hamdy A. Taha, *Operations Research: An Introduction*, 10th Global Edition. Chapter 20, Section 20.2.2, pp.754–757: Inequality Constraints–KKT conditions; Table 20.1 与 Table 20.2 总结 KKT 充分性条件与符号约定。
4. Frederick S. Hillier and Gerald J. Lieberman, *Introduction to Operations Research*, 2024 Release. Section 13.6: Karush–Kuhn–Tucker conditions for constrained optimization; 定理中明确提到 differentiable functions satisfying certain regularity conditions.
5. 课堂课件: 非线性规划第 3 章, 尤其 §3.2 凸函数和凸规划、§3.5 约束最优化方法、Kuhn–Tucker 条件、Fritz John 条件、罚函数法与障碍函数法。